Programmieren von Spiele-KI mit neuronalen Netzen

Livio D'Agostini

27. Januar 2019

Inhaltsverzeichnis

1 Einleitung

In den letzten fünf bis zehn Jahren hat sich in einem Unterbereich der Informatik, dem der künstlichen Intelligenz, viel verändert. Der heute erreichte Forschungsstand ermöglicht Resultate, die erste Anwendungen in der Industrie haben, zum Beispiel in der Bilderkennung, der Musik- und Spracherkennung oder dem autonomen Fahren. [4]

An dieser Stelle muss erwähnt werden, dass sich nicht das ganze Gebiet names "KI"weiterentwickelt hat, sondern in der Tat nur ein kleiner Teil namens machine learningünd in diesem wiederum nur der Teil des "deep learning". Deep learning, zu welchem die mathematischen Grundlagen im nächsten Kapitel beschrieben werden, ist der Grund hinter der ganzen medialen wie wissenschaftlichen Aufregung, die sich seit 2012 eingestellt hat.[7]

Es sollte deshalb nicht verwundern, dass man sich für dieses Thema interessieren kann und die Maturaarbeit deshalb im Bereich des deep learning schreiben will. Meine Zielsetzung war es, eine kleine auf deep learning basierende KI schreiben, die ein einfaches Spiel spielen kann. Für Letzteres bot sich Tic-Tac-Toe an (welches in meiner Arbeit und Code immer wieder als TTT abgekürzt wird). Wie sich während der Arbeitsphase bald zeigte, reichen die Methoden des deep learning noch nicht aus, um eine Spiele-KI zu machen, es wird zusätzlich noch reinforcement learning bzw. deep reinforcement learning benötigt. Beide Bereiche verfügen über eine solche immense Breite von verschiedenen Methoden, was eine vollständige Behandlung der Themen verunmöglicht. In der Tat wird in dieser Arbeit im Bereich des deep learning wie reinforcement learning jeweils nur auf die einfacheren Methoden eingegangen. Es zeigt sich jedoch, dass diese für ein Spiel wie TTT ausreichen.

Informationen zum Thema habe ich zum grössten Teil im Internet gefunden. Es ist allerdings auch ein Buch zu nennen: Neuronale Netze selbst programmieren"von Tariq Rashid [5] hatte ich gelesen, bevor ich mich zu dieser Arbeit entschloss. Es konnte mich überzeugen, dass deep learning keine Hexerei darstellt und dass eine Arbeit in diesem Bereich durchaus machbar ist.

2 Theorie Teil 1: Künstliche Neuronale Netze

Künstliche neuronale Netze sind ein zentraler Bestandteil dieser Arbeit. Es ist deshalb unerlässlich, sich mit ihnen genauer auseinanderzusetzen. In diesem Kapitel werden die grundlegenden Konzepte hinter diesen Netzenërklärt, allerdings reichen diese noch nicht aus, um eine SSpiele-KIßu programmieren, was erst im zweiten Teil der Theorie gezeigt wird.

2.1 Ziel des *machine learning* im Allgemeinen

Heutzutage gibt es viele Bereiche in der Wissenschaft, wo der Computer zur Anwendung kommt: Als Simulationswerkzeug in der Physik, der Biologie, der Chemie oder der Geologie, als Sammler, Speicherer und Auswerter von Datenmengen in der Statistik und in den Sozialwissenschaften. Auffallend ist, dass die Programmierer dabei immer bis ins Detail wissen, was genau sie implementieren müssen: Der Physiker zum Beispiel kennt die Formeln, die seine Simulation benötigt, in und auswendig.
In unserer Welt exisieren aber auch Problemstellungen, zu welchen selbst den schlauesten Köpfen keinen Algorithmus und keine Formel einfällt. Einer der Klassiker ist: Der Computer soll sich ein Bild ansehen und es einer Klasse wie Katze, Flugzeug oder Fussgängerstreifen zuordnen.
Genau diese ïnteressanten Probleme"will das machine learning lösen: Solche, bei denen die Menschheit die Lösung noch nicht kennt.
Neuronale Netze muss man, gleich wie Algorithmen, als mathematische Funktion auffassen. Das bedeutet, dass sie ein Ëtwasïn ein anderes Ëtwas"überführen, zum Beispiel ein x in ein y nach der Regel einer Funktion:

$$y = f(x) | z.B. : f(x) = x^2$$

x ist so etwas wie ein Input, y gleicht analog einem Output. Dieses f ist das, was wir suchen. Es ist der Zusammenhang zwischen Input und Output. Nach obiger Problemstellung:

$$Bildbeschreibung = unbekannteFunktion(Bildchen)$$

Wie gesagt soll das unbekannte f gefunden werden. Machine learning löst dieses Problem mit folgendem Ablauf:

1. Wir suchen eine allgemeine Funktion (das *neural network*), und setzen es für die Funktion ein, die wir nicht kennen, obwohl die beiden Funktionen noch Nichts miteinander zu tun haben. Das neural network enthält anpassbare Parameter, die es uns ermöglichen, jede beliebige Funktion zu modellieren.

2. Mit einem grossem Satz von Datensets gehen wir nun ans Werk: Jeder Schritt besteht aus einem Input zum Netz, wobei die Funktion ausgerechnet wird. Anschliessend vergleicht man die Ausgabe mit einer Musterlösung, um zu erkennen, wie richtig das network momentan ist. Mithilfe von einer Fehlerfunktion und des Backpropagation-Algorithmus lassen sich die Parameter des networks ein wenig verändern, so dass diese in jedem Fall einen Schritt in die richtige Richtung tun. Wenn das Netzwerk mit immer mehr Beispielen angepasst wird, dann wird es sich immer genauer an die unbekannte Funktion annähern. Schlussendlich hoffen wir, dass der Unterschied zwischen der unbekannten Funktion und unseres networks, unserer Approximation, so klein wie möglich wird: In diesem Fall IST das Neuronale Netzwerk gleich der unbekannten Funktion, und so haben wir diese gefunden!

3. Nun kann man das trainierte Netz für Anwendungzwecke nutzen.

Im Folgenden Teil werden die einzelnen Schritte genauer beschrieben.

2.2 Ein Netz definieren

Es gibt zwei Punkte, die eine beliebige Funktion erfüllen muss, so dass sie sich für machine learning eignet:

- Sie muss so viele verschiedene Funktionen annähern können, wie nur irgendwie möglich ist. Deshalb muss sie anpassbare Parameter enthalten, durch welche sie sich verändern kann.

- Es muss klar sein, wie die oben genannten Parameter angepasst werden können. Die einzige Informationquelle, auf welche diese Üpdate-Regelßurückgreifen darf, sind die Daten, mit denen das Netz trainiert wird; Das sind viele Paare der Art (Input, korrekter Output).

Neuronale Netze jeglicher Ausprägung erfüllen diese Punkte. Um das Vorgehen im *machine learning* zu erklären, wird hier nur das sogennante MLP/dense-layer/fully-connected-neural network beschrieben. Es ist das am Wenigsten komplizierte der Netze. Es ist im Wesentlichen aus miteinander verbundenen Perzeptronen aufgebaut; Dabei handelt es sich um eine Abstrahierung der echten biologischen Neuronen[8].

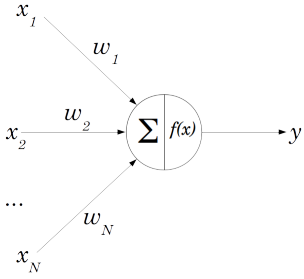

Ein künstliches Neuron, auch Perzeptron genannt, sieht folgendermassen aus:

[2] Ein Perzeptron darf beliebig viele Inputs haben, das heisst beliebig viele Signale dürfen eintreffen. Alle Inputs sind gewichtet: Jeder Input-Wert wird mit einem Gewicht-Wert multipliziert. Das Gewicht ist ein Wert in R. Diese Massnahme simuliert die Signalstärke des sendenden Neurons. Gleichzeitig erzeugt dies die Möglichkeit, dass ein Signal dämpfend/inhibitorisch wirken kann. Alle gewichteten Inputs werden zusammengezählt und bilden damit das Signal. Dieses wird an eine Aktivierungsfunktion weitergegeben. Die Ausgabe dieser wird zum Output des Perzeptrons. Dies simuliert, nach dem Vorbild eines echten Neurons, die Entscheidung ob sie feuert oder nicht. Die Aktivierungsfunktion ist aber nur selten eine Stufenfunktion, so wie sie nach dem biologischen Vorbild sein sollte. Nun kann man z.B. mehrere dieser Perzeptrons hintereinander oder nebeneinander stellen. In den meisten Fällen sind die Perzeptronen schichtenhaft angeordnet, wobei alle Perzeptronen der vorherigen mit denen der nachfolgenden Schicht verbunden sind. Die erste Schicht nimmt den Input des Netzes an, die Letzte repräsentiert die Ausgabe. Dadurch entstehen MLPs (multilayer-

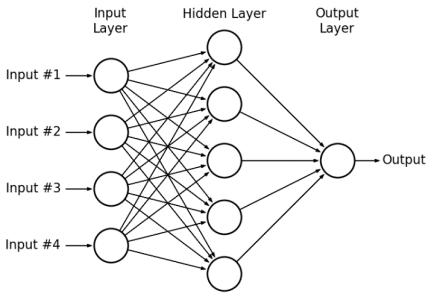

perceptrons). [9] Natürlich steht es jedem offen, sein Netzwerk von Perzeptronen (innerhalb von Netzen meistens "Knoten"genannt, wenn überhaupt) auf beliebig komplizierte Art zu modellieren, jedoch ist es fraglich, wie viel besser ein spezielles Netz sein würde verglichen mit einem Normalen, welches einem Schichtenaufbau folgt. Zwischen den Schichten liegen die Gewichte, je eines für jede Verbindung. Als Aktivierungsfunktionen wurden historisch Sigmoid- und Tangens(hyperbolicus)funktionen verwendet[Quelle???], welche eine Art SSForm haben. Der heutige Standard heisst ReLU und ist wie folgt definiert:

$$ReLU(x) = max(0, x)$$

D.h., alle negativen Werte werden auf null gesetzt, alle andern bleiben gleich. Weshalb ReLU so gut funktioniert, ist nicht vollständig geklärt[quelle?], jedoch hat sich ReLU in der Praxis durchgesetzt. Intuitiv darf man sich vorstellen, dass bestimmte Knoten im MLP einen ganz bestimmten Sinn relativ zum ganzen Netz besitzen, z.B. ein Netz, dass Bilder zuordenen soll, muss evtl. an einer Stelle ëntscheiden"können, ob ein bestimmtes Merkmal im Input vorhanden ist. ReLU, so stellt man sich vor, hilft, Werte, die zu einem bestimmten Merkmal korrespondieren, auf null zu setzen, wenn das Merkmal in einem bestimmten Bild nicht vorhanden ist. Ein weiterer Vorteil des Schichtenaufbaus liegt darin, dass alle Gewichte in eine Matrix geschieben werden können. Zum Beispiel liegen alle Gewichte, die für Verbindungen zum ersten Knoten

zuständig sind, in der ersten Zeile der Matrix. Hat man jetzt einen Vektor von Inputs, so lassen sich die Inputs für Knoten der zweiten Schicht mit einer Matrixmultiplikation berechnen:

$$in2 = dotp([weights], in1)$$

Dank dieser Formel ist erkennbar, dass Neuronale Netze nicht unbedingt als Netzeöder als Systeme von Verbindungen gesehen werden müssen. Eigentlich wird ein Vektor weitergegeben, der auf dem Weg wiederholt mit einer Matrix von Gewichten multipliziert und elementweise einer Aktivierungsfunktione übergeben wird. Die Anfangs beschriebene Perzeptronen sind nicht mehr sichtbar. Die Architektur eines Netzes definiert den forward pass. Damit ist das Berechnen der Ausgabe abhängig einer Eingabe gemeint. Im Fall vom obigen MLP:

$$forward_pass(in0) = ReLU(dotp([weights1], ReLU(dotp([weights0], in0))))$$

Auf den ersten Input in0 wird nach Konvention meistens keine Aktivierungsfunktion angewendet[pinkbook]. Die Gewichte sind entscheidend: Sie sind die anpassbaren Parameter. Der totale Zustand der Gewichte entscheidet über das Verhalten des Netzes. In der Theorie ist bewiesen, dass ein MLP von genügender Grösse und richtig gewählten Gewichten jede erdenkliche (kontinuierliche) Funktion annähern kann[paper???]. Natürlich weiss man nicht, was die korrekten Wahlen für die Gewichte sind. Um trotzdem Gewichte sinnvoll setzen zu können, hat man Backpropagation (im Deutschen als Fehlerrückführung bekannt) erfunden. Benötigt werden viele Datenpaare mit der Form:

$$(Input, verlangterOutput)$$

Zuerst wird das NN initalisiert, das heisst alle Gewichte erhalten einen zufälligen Wert. Nun werden die Gewichte schrittweise verbessert, in jedem Schritt durchläuft man die folgende Prozedur: Man nimmt ein Datenpaar und macht einen forward pass mit dem Input. Das erzeugt eine Ausgabe, die insbesondere zu Beginn des Trainings weit vom verlangten Output liegt. Als nächstes benötigt man eine Methode, die uns sagt, wie falsch die Ausgabe zum Verlangten ist und abgeleitet davon wie unrichtig das NN ist. Die Funktion, die dies tut, heisst Fehlerfunktion oder loss function. Meistens benutzt man den L1 oder den L2 loss[Quelle???]:

$$L1(out, verlangt) = sum(out - verlangt)$$

$$L2(out, verlangt) = sum((out - verlangt)^2)$$

Das sum() wird nur benötigt, um den loss als eine Zahl darzustellen. Für Backpropagation wird der intakte loss-Vektor benötigt. Bis jetzt kann man eine Aussage darüber machen, wie falsch das NN insgesamt ist, man interessiert sich aber nur für Aussagen

über jedes einzelne Gewicht. Im Folgenden wird die oft genannte Backpropagation beschrieben.

2.3 Fehlerrückführung - Backpropagation

Verfügt man über ein Neuronales Netz $nn(\phi)$, ein Trainingsbeispiel $t = (x, y)$ und eine loss-Funktion E, dann kann man eine Version von nn erzeugen, die Parameter benutzt, durch welche E kleiner wird, also besser wird. Die Idee ist, dass E nach den (allen) Parametern abgeleitet werden muss. Die Bedeutung der Ableitung ist gross: Sie sagt, wie sich ganz E verändert, wenn die Parameter angepasst werden. Addiert man die Ableitung zum Parameter, dann wird E grösser, deshalb addiert man die negative Ableitung, was E verkleinert. Ein Beispiel:

$$f(x) = -3x + 42, \frac{df}{dx} = -3$$

Setzt man x auf 15, dann ist $f(15) = -3$. Addiert man $f'(x)zux$, so wird x zu 12, und $f(12) = 6$, also grösser als -3. Jedes Gewicht kann dann mit seiner partiellen Ableitung verbessert werden:

$$w_{ij}^k = w_{ij}^k - \alpha \frac{dE}{dw_{ij}^k}$$

Das ist die Update-Regel des Gewichts, welches die (k-1)-te Schicht mit der k-ten Schicht verbindet, nämlich von Knoten i in der vorherigen zu Knoten j in der k-ten Schicht (siehe Diagramm MLP). Das α oben ist ein arbiträrer Wert, der später als Lernrate bezeichnet wird. Meistens ist dies ein Wert in $]0, 1]$, der ein verfeinertes Anpassen der Parameter erlaubt. Der schwierigste Teil von Backpropagation ist jedoch das Ausrechnen der Ableitung selbst, weil die Netzstrukturen von nn sehr kompliziert werden können. Im Fall eines MLPs lässt sich dies relativ einfach nachvollziehen.

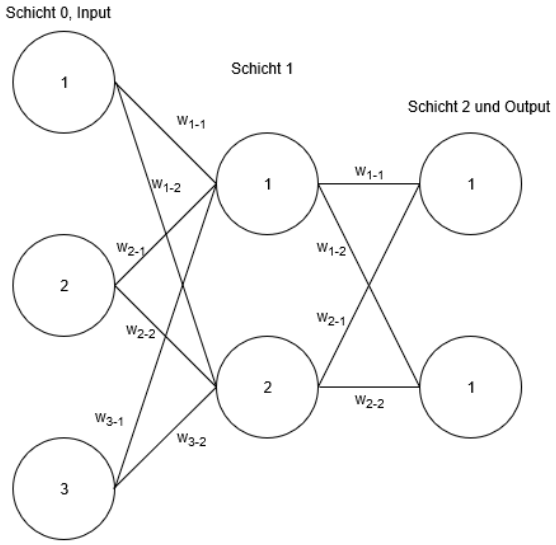

[3] Die Ableitung dE/dwkij lässt sich

aufspalten zu:

$$\frac{dE}{da_j^k}\frac{da_j^k}{dw_{ij}^k}$$

a_j^k ist dabei die Summe aller Inputs zum Knoten j in der k-ten Schicht bevor die Aktivierungsfunktion wie Sigmoid oder ReLU angewendet wird. $\frac{da_j^k}{dw_{ij}^k}$ ist nun einfach zu lösen: $a_j^k = \sum_{I=0}^{n}(w_I^k j o_I)$; o_I ist die Ausgabe vom I-ten Knoten in der vorherigen Schicht. Weil man nach einem bestimmten w_{ij}^k ableitet, fallen alle ausser folgender Summand weg: $w_{ij}^k o_i$;d.h. wenn $I = i$. Somit ist die Ableitung von $\frac{da_j^k}{dw_{ij}^k} = o_i$. $\frac{dE}{da_j^k}$ ist mühsamer, denn a_j^k kann in jeder Schicht sein. Wüsste man jedoch $\frac{dE}{da_l^{k+1}}$, dann hätte man $\sum(\frac{dE}{da_j^{k+1}}\frac{a_l^{k+1}}{a_j^k})$; a_l^{k+1}/a_j^k ergibt $w^{k+1} * func'(a_j^k)$. Dadurch wird die Ableitung nach a_j^k abhängig von allen a_l^{k+1} aus der nachfolgenden Schicht gemacht. Wichtig ist, dass $\frac{dE}{da^{last}}$, die Knoteninputs zur letzten Schicht, berechnet werden können, was der Fall ist: $\frac{dE}{da^{last}} = 2(o^{last} - y)func'(a^{last})$ für alle a^{last} in der letzten Schicht (mit entsprechendem Index). Zusammengesetzt ergibt das:

$$\frac{dE}{dw_{ij}^k} = func'(a_j^k)o_i^{k-1}\sum(w_{jl}^{k+1}\frac{dE}{da_l^{k+1}})$$

mit $\frac{dE}{da_j^k} = w^{k+1}func'(a_j^k)$ für die vorherige Schicht. Nun werden die Schichten von hinten nach vorne durchlaufen, damit die notwendigen dE/dak+1l fortlaufend berechnet werden können. Dank der Backpropagation ist es möglich, ein Neuronales Netz zu jeder loss-Funktion zu optimieren - bis zu einem gewissen Grad natürlich.

3 Theorie Teil 2: Deep Reinforcement Learning

Ein herkömmliches Neuronales Netz, wie zum Beispiel ein CNN, reicht noch nicht aus, um eine KI zu erstellen, die in der Umgebung eines Spiels richtige Entscheidungen treffen kann. Weshalb? Die Netze, die bisher besprochen wurden, gehören zum Teilgebiet des 'Supervised Learning' (etwa: Überwachtes Lernen). Bei diesem Konzept verfügt man immer über DatenSETS, welche in der Form (Trainigsdaten, Korrekte Antwort) verfügbar sind. Will man ein CNN dazu bringen, Bilder zu einer bestimmeten Klasse zuzuordnen, so benötigt man Datensets der Art (Bild, Klasse). Glücklicherweise existieren Datenbanken zu diesem Zweck, zum Beispiel das ImageNet. Wichtig ist, dass man erkennt, dass diese Datensets durch Menschenhand erstellt wurden. Grundsätzlich liesse sich dies auch für Spiele machen: Im Fall von Schach könnte man ein Expertenteam von Profischachspielern anstellen, die Unmengen von Stellungen durchgehen würden, um bei jeder ensteiden würden, was am Besten zu spielen sei; Auch könnte ein herkömmliches Schachprogramm diese Aufgabe übernehmen. Die Sache hat jedoch einen Haken: Ein Neuronales Netz wird immer versuchen, die 'Lösung', so gut wie es möglich ist, nachzuahmen. Deshalb kann es

niemals besser als die Lösung werden. Ausserdem hat Niemand bewiesen, dass die Angaben der Profispieler oder des Schachprogramms mit Sicherheit korrekt wären (angesichts der Tatsache, dass AlphaZero besser als Stockfish spielt, muss man das wohl annehmen)[QUELLE]. Aus diesem Gründen wird klar, dass klassisches 'Supervised Learning' nur beschränkten Erfolg als Spiele-KI haben kann. Wäre es denn möglich, die KI zu bauen, die nicht solche Lösungen oder Labels benötigt? Genau mit dieser Frage beschäftigt sich (Deep) Reinforcement Learning. Im Folgenden werden einige Methoden und Konzepte aus diesem Bereich behandelt.

3.1 Markov Desicion Process (MDP)

Um besser verstehen zu können, welche Eigenschaften eine Spiele-KI haben muss, führt man ein mathematisch formales Konzept ein, welches die Grundeigenschaften eines Spiels verkörpert. Damit sind einfache Tatsachen gemeint, wie zum Beispiel dass das Spiel in eine neue Stellung übergeht, nachdem der Spieler einen Zug ausgeführt hat. Man nennt das System einen Markov Desicion Process, benannt nach dem russischen Mathematiker Andrej Markov, der es formuliert hat[wikipedia].

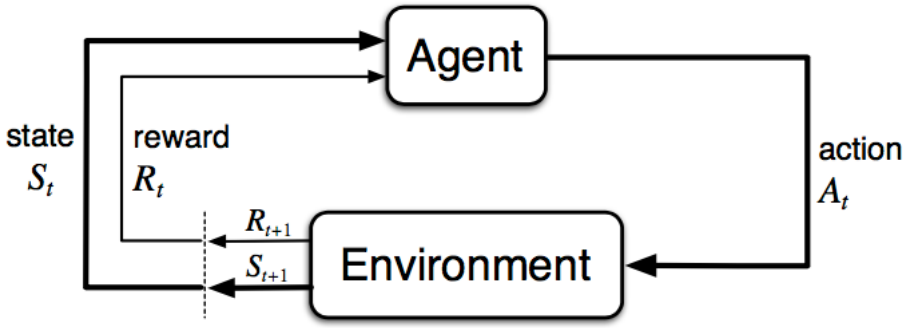

[1] Die Beziehung zwischen diesen Variablen und Funktionen ist im obigen Bild dargestellt: Es gibt einen 'Agent', den Spieler/der Handelnde, und das Environment, die Umgebung, bei uns das Spiel. Das MDP ist ein zeitlicher Ablauf: Es startet mit einer bestimmten Start-Stellung, durchläuft dann Zeitschritte (entweder unendlich lang oder endet beim Erreichen einer bestimmten End-Stellung). Bei jedem Zeitschritt erhält der Agent vom Environment die neue Stellung s und die Belohnung r betreffend den vorherigen Zeitschritt (und evtl. die verfügbaren Aktionen aus A), er wählt ein a aus, schickt es zurück ans Environment und nun beginnt der nächste Zeitschritt... Man definiert:

S und s; wobei S für die Menge aller möglichen Stellungen steht, und s für ein Element aus dieser Menge

$A(s)$ und a; wobei A(s) die Menge aller in einer Stellung erlaubten oder möglichen Aktionen (= Züge) steht und wiederum a als Element aus A(s)

$T(s, a) -> s'$; eine Funktion, die ein s' berechnet abhängig der Stellung s und der Aktion a, die sie erhalten hat - es sei angemerkt, dass es sich dabei um eine

Verteilung handelt, s und a bestimmen lediglich, welches s' wahrscheinlicher ist

$R(s,a) -> r$; eine Funktion, die eine Belohnung r für das a berechnet, das in s genommen wurde - kann ebenfalls aus einer Verteilung stammen

Das Ziel ist es nun, den Agenten so steuern, dass r über das gesamte Spiel hinweg gesehen maximal ist.

3.2 Q-Learning

Der totale noch erreichbare *reward* aus einer Position s ist definiert als G:

$$G(s) = \sum_{t}^{EndedesSpiels} y^i r_t$$

Es wird also einfach jegliche Belohnung zusammengezählt, die im weiteren Spielverlauf noch dazukommt. y ist dabei ein Faktor, der im Bereich $[0,1]$ liegt und Belohnungen, die noch in weiter Ferne liegen, abschwächt. Der Grund zu seiner Existenz liegt in ein paar mathematischen Annehmlichkeiten[see 6, Value Function]. Nun stellt man sich eine Funktion vor, die den *expected future reward* in Abhängigkeit vom momentanen Spielstand und einer möglichen Aktion weiss:

$$Q(s,a) = Erwartungswert(G(s)|s,a)$$

Die Funktion erhält den Buchstaben Q, was evtl. für "Qualityßteht. $Q(s,a)$ ist praktisch: Weiss man sie, so kann man direkt ein sinnvolles Verhalten für den agent ableiten: Man kann alle möglichen Züge nach ihrem Q-Wert abfragen und schliesslich denjenigen mit dem höchsten auswählen. Das ist als "greedy-policy"bekannt. Es ist nur selten möglich, eine Q-Funktion einfach so zu besitzen. Meistens muss sie approximiert werden. Dazu hilft die Bellman-Gleichung, die die Rekursivität der Q-Funktion deutlich macht.

$$Q(s,a) = Erwartung(r_t + y \cdot Q(s_{t+1}, a_{t+1})|s,a)$$

Die Summe aus G wird vereinfacht, indem alle ausser der erste Summand durch $y \cdot Q(s_{t+1}, a_{t+1})$ zusammengefasst wird. s_{t+1} ist dabei einer der Schwachpunkte. Die Funktion $T(s,a)$ ist probabilistisch - s_{t+1} kann nicht mit aller Sicherheit bestimmt werden. Jedoch genau deshalb ist die Q-Funktion ein Erwartungswert: Mit bestimmten Wahrscheinlichkeiten gelangt man in eine Position s_{t+1}. Jedes s trägt aber implizit einen Wert mit sich, nämlich der der besten Aktion in s_{t+1}. Der implizite Wert eines jeden s ist dadurch:

$$s = \sum_{alles_t+1} max(Q(s_{t+1}, a))P(s_{t+1}|s,a)$$

Jetzt will man wissen, wie man seine Q-Funktion verbessert. Bellman liefert dazu:

$$Q^*(s,a) = Erwartung(r_t + y \cdot max(Q^*(s_{t+1}, a_{t+1})|s,a)))$$

Im Fall der perfekten Q-Funktion muss diese Gleichung für alle s und a erfüllt sein.

3.3 tabulares Q-Learning (=tQL)

Die Q-Funktion wird in tQL als 2d-Liste/Tabelle repräsentiert, wo s und a die Ächsenßind. Trainingsdaten werden durch Spiel-gegen-sich-selbst (self-play) erzeugt. Das heisst, dass ein Spiel simuliert wird, bei dem immer die momentane Q-Liste nach dem besten Zug abgefragt wird, bis das Spiel zuende geht. Bei jedem Zeitschritt werden s, a, r und s' in eine Liste abgespeichert. Das sind alle nötigen Informationen, um ein Update in der Q-Tabelle durchführen zu können:

$$Q[s][a] = Q[s][a](1-\alpha) + (r + y \cdot max(Q[s']))\alpha$$

α ist die Lernrate; Dadurch wird der der neue Eintrag von $Q[s][a]$ aus Anteilen aus dem alten und aus dem neuen Wert zusammengesetzt, die von alpha gewichtet werden. Meistens werden Updates nicht sofort ausgeführt, sondern zu einem späteren Zeitpunkt. Die [s,a,r,s']-Listen werden in einen Speicher aufgenommen, der vor der Trainingsphase zufällig vermischt wird. Das führt zu einer Art experience replay.[6] TQL hat allerdings grosse Schwächen: Q könnte je nach Problemstellung fast unendlich gross werden: Wenn s Teile enthält, die kontinuierlich sind, z.B. ein Wert ist eine Zahl aus R, ist es hoffnungslos, eine Liste aller Möglichkeiten zu führen.

3.4 Deep Q-Learning

Bei Deep Q-Learning(=DQN) errinnert man sich an die Tatsache, das die Q-Funktion, die bei tQL als Tabelle im Hintergrund geführt wird, auch Funktion angesehen werden kann, die durch ein neuronales Netz approximiert wird.

$$DQN(s,a,phi) -> r$$

wobei phi für alle Parameter des Netzes steht. Vorteile sind sofort ersichtlich:

- DQN kann auf einem kontinuierlichen state-space angewendet werden.
- DQN kann states bewerten, die zuvor noch nie durch Spiel-gegen-sich-selbst erreicht wurden.
- Der Speicherverbrauch bleibt konstant.

Die Gewinnung der Trainigsdaten verläuft gleich wie bei tQL: [s,a,r,s']-Listen werden abgespeichert. Die Optimierung des Netzes wird durch folgende loss-Funktion vorgenommen:

$$loss = (DQN(s,a) - (r + y \cdot max(DQN(sn))))^2$$

Es handelt sich dabei um einen MSE-loss zwischen $DQN(s,a)$ und $(r+y \cdot max(DQN(sn)))$. Dadurch wird die Differenz der beiden Terme minimiert, so dass das NN sich immer näher an die Bellman-Gleichung annähert.

4 Methoden

4.1 Tic-Tac-Toe

Ein Einblick in das TTT-Programm, welches zum Spielen und Trainieren notwendig war. Die Basis liegt in einem 2D numpy-array, welches direkt das Spielfeld repräsentiert. Alle Felder werden mit -1 initalisiert. Zieht der erste Spieler, dann wird am entsprechenden Ort eine 0 gesetzt, für den zweiten eine 1. Nach jedem Zug eines Spielers muss überprüft werden, ob das Spiel geendet hat. Bei Spielende wird der Sieger bestimmt. Letzteres ist einfach, denn ein Zug kann nur gewinnen oder Unentschieden herbeiführen, aber nicht verlieren. Ein Remis kann nur entstehen, wenn das ganze Brett gefüllt worden ist, aber keiner der beiden Spieler gewonnen hat. Weil das TTT-Programm erweiterbar sein soll, d.h. auch ein grösseres Spielfeld verarbeiten können soll, ist es nicht ganz offensichtlich, wie man überprüft, ob das Spiel geendet hat. Zum Beispiel könnte die Regel sein auf einem 10x10 Spielfeld nach fünf hintereinanderfolgenden "xßuchen. Um auf einem nxm Feld nach k hintereinanderfolgenden gleichen Zeichen zu suchen, musste ein einfacher Algorithmus entworfen werden, der nach jedem Zug überprüft, ob das Spiel geendet hat. Es wird ausgenutzt, dass im Falle eines Siegs der letzte Zug entscheidend war, d.h. dass das zuletzt gesetzte Feld Teil der mindestens k-langen Linie ist. Deshalb geht der Algorithmus vom Feld des letzten Zugs aus und sucht sternförmig nach allen acht Richtungen nach Feldern, die gleich ausgefüllt sind wie das Anfangsfeld. Schlussendlich muss beachtet werden, dass die sich gegenüberstehenden Richungen (z.B. links oben und rechts unten) in ihrer Länge zusammengezählt werden müssen.

Code:

```
foundinlineX = 1
origin = pos[:] # position vom letzten zug
while pos[0] != 0:
    pos[0] -= 1
    if self.field[pos[0],pos[1]] == who:
        foundinlineX += 1
```

```
            else:
                break
            if foundinlineX == self.numtowin:
                return True
        pos = origin[:]
        while pos[0] < self.field.shape[0]-1:
            pos[0] += 1
            if self.field[pos[0],pos[1]] == who:
                foundinlineX += 1
            else:
                break
            if foundinlineX == self.numtowin:
                return True
```

Code, der nach Lösungen in der Horizontale sucht

4.2 Tabulares Q-Learning

Für die Tabelle habe ich ein Python Standard-dictionary benutzt. Keys sind jeweils die string-Repräsentationen der entsprechenden Positionen aus dem TTT-Programm. Values sind jeweils ein numpy-array mit so vielen Einträgen, wie es actions gibt, also nxm. Sie sind auf null initalisiert.
Die Replay-Liste wird nun angelegt, indem effektiv eine arbiträtre Anzahl Spiele durchlaufen wird. Mit der Q-Tabelle werden für beide Seiten die Züge gespielt, denen der höchste Wert zugeordnet ist; jedoch muss mit einer bestimmen Wahrscheinlichkeit (in meinen Trainingsläufen meistens im Bereich 50-60%) ein zufälliger Zug ausgeführt werden, weil sonst immer das gleiche Spiel gespielt würde, und das würde zu Nichts führen. Ebenfalls wichtig ist, dass nur legale Züge durchgelassen werden. Dies kann der Q-Learning-Algorithmus nicht selbst übernehmen, sondern muss extern gemacht werden.

```
    def query(self,state):
        if str(state) not in self.Q:
            self.Q[str(state)] = np.zeros(self.sz)
        if random.uniform(0,1) < self.random_prob:
            return np.random.choice( TTTGame.get_legal(state) )

        res = self.Q[str(state)]
        besta = -1
        bestr = -1000
        for lglidx in TTTGame.get_legal(state):
            if res[lglidx] > bestr:
                bestr = res[lglidx]
                besta = lglidx
        return besta
```

Abfrage-Funktion

Die Replays werden zufällig vermischt und anschliessend zum Training benutzt. Meistens werden zwischen 1000 bis 5000 Replays gespielt und trainiert. Bei tQL gestaltet sich das Verbessern relativ einfach:

```
    def train(self):
        for replay in self.replay_save:
            s,a,r,sn = replay
            self.Q[str(s)][a] = self.Q[str(s)][a] * (1 - self.lr) + self.
self.choose_from_legal(sn, self.Q[str(sn)]))
```

Trainingsfunktion

4.3 Deep Q-Learning

Für DQN werden viele der oben genannten Konzepte und effektiv Funktionen übernommen. Die Q-Tabelle wird durch ein Neuronales Netzwerk ersetzt, welches mit TF.keras implementiert ist.

```
net = tfk.models.Sequential()
net.add(tfk.layers.Dense(50,input_shape=(9*3)),activation=tfk.activations
net.compile(optimizer=tfk.optimizers.SGD(lr=0.1),
                              loss=tfk.losses.MSE,
                              metrics=[tfk.metrics.MAE])
```

Beispiel für das Erstellen eines Netzwerks mit zwei dense(aka normalen)-Schichten Mit den Methoden net.predict und net.fit lässt sich das Netz abfragen bzw. trainieren. Gleich wie beim Tabellenansatz muss die Ausgabe des Netzwerks mit einer Maske der noch möglichen Züge verglichen werden. Die train-Funktion ändert am Stärksten, weil die [s,a,r,s']-Listen für die net.fit-Funktion aufbereitet werden müssen.
DQN hat einen Input, der dreimal so gross ist wie das das TTT-Feld. Das liegt an verwendeten one-hot encoding. Dabei wird die TTT-Position mit z.B. 3x3 Feldern, die jeweils einen Wert von -1,0 oder 1 besitzen, so umgeschrieben, dass jedes Feld mit einem Vektor der Länge 3 ersetzt wird. Diese Vektoren enthalten nur 0 und genau eine 1. Der Index, bei dem die 1 steht, hat dann die ursprüngliche Bedeutung. So steht der Index 0 für -1, 1 für 0 und 2 für 1. Bsp.

$$[[-1,-1,0],[-1,0,1],[1,0,-1]] wirdzu : [1,0,0],[1,0,0],[0,1,0],....[0,0,1],[0,1,0],[1,0,0]$$

One-hot encoding ergibt Sinn im Fall von TTT, weil die Bedeutung der Werte -1,0,1 für leer,Spieler0,Spieler2 gewissermassen nicht kontinuierlich/linear ist. Wäre es so, würde das heissen, dass ein grösserer Input für eine proportional grössere Bedeutung steht. Aber ein Wert von 12 hat keine Bedeutung in TTT. Ein NN will aber, dass der Input eine lineare Bedeutung hat. Das liegt hauptsächlich daran, dass das Netzwerk intern die Werte nur multipliziert und addiert (insbesondere wenn ReLU benutzt

wird). Bei one-hot encoding erschafft man deshalb eine Dimension für jeden diskreten Wert.

Der Code ist auf Github unter https://github.com/ldzgch/TTTlearning verfügbar.

5 Resultate

6 Fazit

Literatur

[1] billy-inn. *Notes on Reinforcement Learning (1): Finite Markov Decision Processes*. 2016. URL: http://billy-inn.github.io/blog/2016/10/05/notes-on-reinforcement-learning-1-finite-markov-decision-processes/.

[2] Philippe Lucidarme. *Simplest perceptron update rules demonstration*. 2017. URL: https://www.lucidarme.me/simplest-perceptron-update-rules-demonstration/.

[3] *Mithilfe von Draw.io selbstgezeichnete Diagramme*. URL: draw.io.

[4] Vartul Mittal. *Top 15 Deep Learning applications that will rule the world in 2018 and beyond*. 2017. URL: https://medium.com/@vratulmittal/top-15-deep-learning-applications-that-will-rule-the-world%20in-2018-and-beyond-7c6130c43b01.

[5] Tariq Rashid. *Neuronale Netze selbst programmieren*. 2017.

[6] Lilian Weng. *A (Long) Peek into Reinforcement Learning*. 2018. URL: [https://lilianweng.github.io/lil-log/2018/02/19/a-long-peek-into-reinforcement-learning.html].

[7] Wikipedia. *Deep Learning*. 2019. URL: https://en.wikipedia.org/wiki/Deep_learning#Deep_learning_revolution.

[8] Wikipedia. *Perceptron*. 2019. URL: https://en.wikipedia.org/wiki/Perceptron#History.

[9] Mohamed Zahran. *A hypothetical example of Multilayer Perceptron Network*. 2015. URL: https://www.researchgate.net/figure/A-hypothetical-example-of-Multilayer-Perceptron-Network_fig4_303875065.